

TALLER NLP

# Agentes financieros sobre informes 10-K

Evolución de tres agentes y comparación de resultados


Higinio   Hugo   Javier

24 de septiembre de 2026

# Higinio · búsqueda y control de la respuesta

Gemini 3.8 Flash / Gemma 4 26B A4B    Embeddings: BGE-small-en-v1.5

Aciertos sobre las 20 preguntas del equipo



## La restricción que restó

El esquema comparativo rígido bajó el resultado a 13/20.

## Versión elegida: v018


Búsqueda híbrida, evidencia y verificación XBRL.  
Ausencias: 12/12 adicionales.

Gemma, en v016: 13/20 con menor coste. Embeddings constantes.

# Hugo · formato, comparativas y decimales

Claude Haiku 4.5 / Sonnet 5    Embeddings: BGE-small-en-v1.5

Sonnet 5: aciertos sobre las 20 preguntas del equipo



**El 20/20 ocultaba un fallo**

Prueba de estrés: 5/8 a 8/8.  
El control XBRL recuperó  
los decimales del beneficio  
por acción.

**Apple 2025: 7,00 a 7,46  
USD/acción**

Haiku v001: 7/20. Sonnet v005: 20/20. Mismo modelo de embeddings.

# Javier • menos llamadas y abstención precisa

DeepSeek V4 Flash 0731    Embeddings: Voyage 4 Lite (1.024 dimensiones)

| Versión     | Equipo + oficial | Casos sin dato    | Cambio principal                      |
|-------------|------------------|-------------------|---------------------------------------|
| v1          | 37/40            | Sin evaluar aquí  | Validación propia, hasta 18 llamadas  |
| v2          | 40/40            | 5/12 <sup>1</sup> | Prompt simplificado, hasta 6 llamadas |
| v3 ajustada | 40/40            | 12/12             | Abstención y etiquetas de ingresos    |

52/52

v3: 40 preguntas conocidas + 12 casos de ausencia.  
Mismos modelos y recuperador durante la evolución.

<sup>1</sup> Campaña adicional de v2. La v3 incorpora la regla de abstención propuesta por Higinio.

# Qdrant · recuperación con contexto de sección

Javier

## 1.749

vectores del corpus reutilizados

Docker local

1.024 dimensiones por fragmento

Filtros por empresa, año y sección

**01 La consulta se convierte en un vector**

**02 Qdrant encuentra fragmentos con filtros**

**03 El agente recibe la sección completa**

Los modelos y embeddings se ejecutan en la nube.  
El corpus tiene caché de vectores. Las consultas no.

# Prueba ciega · 10 preguntas nuevas

Resultados pendientes de la sesión del 24 de septiembre

## Los conjuntos de desarrollo ya los conocemos

La prueba nueva medirá cuánto se mantiene el resultado fuera de esas preguntas.

### Por registrar

Aciertos sobre 10  
Abstenciones correctas  
Coste y tiempo  
Diferencia frente al  
desarrollo

Se ejecutará el código entregado. Aún no hay una puntuación ciega.

# Comparativa de las mejores configuraciones

Mismas 20 preguntas del equipo. Medias por pregunta.

|                         | Higinio · v018    | Hugo · v005       | Javier · v3          |
|-------------------------|-------------------|-------------------|----------------------|
| LLM                     | Gemini 3.8 Flash  | Claude Sonnet 5   | DeepSeek V4 Flash    |
| Embeddings              | BGE-small-en-v1.5 | BGE-small-en-v1.5 | Voyage 4 Lite        |
| Aciertos                | 20/20             | 20/20             | 20/20                |
| Coste (USD)             | 0,00835           | 0,0342            | 0,00124 <sup>1</sup> |
| Latencia / herramientas | 14,92 s / 2,50    | 12,00 s / 2,75    | 18,21 s / 2,90       |

Empate en acierto. Hugo fue más rápido. Javier registró menor coste.

<sup>1</sup> Excluye embeddings de consulta. Hugo: cifras del README. Pasadas distintas, sin aislar el efecto del LLM.