

TALLER NLP

Agentes financieros sobre informes 10-K

Evolución de tres agentes y comparación de resultados

Higinio Hugo Javier

24 de septiembre de 2026

Higinio · búsqueda y control de la respuesta

Gemini 3.8 Flash / Gemma 4 26B A4B Embeddings: BGE-small-en-v1.5

Aciertos sobre las 20 preguntas del equipo

La restricción que restó

El esquema comparativo rígido bajó el resultado a 13/20.

Versión elegida: v018

Búsqueda híbrida, evidencia y verificación XBRL.
Ausencias: 12/12 adicionales.

Gemma, en v016: 13/20 con menor coste. Embeddings constantes.

Hugo · formato, comparativas y decimales

Claude Haiku 4.5 / Sonnet 5 Embeddings: BGE-small-en-v1.5

Sonnet 5: aciertos sobre las 20 preguntas del equipo

El 20/20 ocultaba un fallo

Prueba de estrés: 5/8 a 8/8.
El control XBRL recuperó
los decimales del beneficio
por acción.

**Apple 2025: 7,00 a 7,46 USD/
acción**

Haiku v001: 7/20. Sonnet v005: 20/20. Mismo modelo de embeddings.

Javier • menos llamadas y abstención precisa

DeepSeek V4 Flash 0731 Embeddings: Voyage 4 Lite (1.024 dimensiones)

Versión	Equipo + oficial	Casos sin dato	Cambio principal
v1	37/40	Sin evaluar aquí	Validación propia, hasta 18 llamadas
v2	40/40	5/12 ¹	Prompt simplificado, hasta 6 llamadas
v3 ajustada	40/40	12/12	Abstención y etiquetas de ingresos

52/52

v3: 40 preguntas conocidas + 12 casos de ausencia.
Mismos modelos y recuperador durante la evolución.

¹ Campaña adicional de v2. La v3 incorpora la regla de abstención propuesta por Higinio.

Qdrant · recuperación con contexto de sección

Javier

1.749

vectores del corpus reutilizados

Docker local

1.024 dimensiones por fragmento

Filtros por empresa, año y sección

01 La consulta se convierte en un vector

02 Qdrant encuentra fragmentos con filtros

03 El agente recibe la sección completa

Los modelos y embeddings se ejecutan en la nube.

El corpus tiene caché de vectores. Las consultas no.

Baseline frente a versión definitiva

Mismas 20 preguntas del equipo · Métricas medias por pregunta

Métrica	Baseline	Versión definitiva
Cita	42,9 %	100,0 %
Cifra	85,7 %	100,0 %
Trayectoria	75,0 %	100,0 %
Recall@5	42,9 %	85,7 %
Aciertos extractiva	5/6	6/6
Aciertos numérica	6/6	6/6
Aciertos comparativa	0/8	8/8
Coste medio (¢)	0,7592	0,1234
Latencia media (s)	14,87	16,34
Llamadas/pregunta	3,10	2,80

Jchulvi v3: 20/20 frente a 11/20 y un 83,7 % menos de coste.

Prueba ciega · 10 preguntas nuevas

Resultados pendientes de la sesión del 24 de septiembre

Los conjuntos de desarrollo ya los conocemos

La prueba nueva medirá cuánto se mantiene el resultado fuera de esas preguntas.

Por registrar

Aciertos sobre 10
Abstenciones correctas
Coste y tiempo
Diferencia frente al
desarrollo

Se ejecutará el código entregado. Aún no hay una puntuación ciega.